


UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



# DETEKCIA ABNORMÁLNEHO SPRÁVANIA

Diplomová práca

2019

Bc. Martin Sadloň

UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



# DETEKCIA ABNORMÁLNEHO SPRÁVANIA

Diplomová práca

Študijný program: Aplikovaná informatika  
Študijný odbor: 2511 Aplikovaná informatika  
Školiace pracovisko: FMFI.KAI - Katedra aplikovanej informatiky  
Školiteľ: RNDr. Zuzana Černeková, PhD.

Bratislava, 2019

Bc. Martin Sadloň



Univerzita Komenského v Bratislave  
Fakulta matematiky, fyziky a informatiky

## ZADANIE ZÁVEREČNEJ PRÁCE

**Meno a priezvisko študenta:** Bc. Martin Sadloň  
**Študijný program:** aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)  
**Študijný odbor:** aplikovaná informatika  
**Typ záverečnej práce:** diplomová  
**Jazyk záverečnej práce:** slovenský  
**Sekundárny jazyk:** anglický

**Názov:** Detekcia abnormálneho správania  
*Abnormal behaving detection*

**Anotácia:** Naštudovať metódy počítačového videnia zaoberajúce sa rozpoznávaním ľudského správania. Analyzovať existujúce riešenia publikované v dostupnej odbornej literatúre. Navrhnuť vlastnú metódu, ktorá dokáže rozpoznať niektoré neštandardné typy správania sa v dave ako napríklad bitka, osoba ležiaca na zemi a podobne. V závere túto metódu otestovať a vyhodnotiť dosiahnuté výsledky.

**Cieľ:** Naštudovať metódy počítačového videnia zaoberajúce sa rozpoznávaním ľudského správania. Analyzovať existujúce riešenia publikované v dostupnej odbornej literatúre. Navrhnuť vlastnú metódu, ktorá dokáže rozpoznať niektoré neštandardné typy správania sa v dave ako napríklad bitka, osoba ležiaca na zemi a podobne. V závere túto metódu otestovať a vyhodnotiť dosiahnuté výsledky.

**Vedúci:** RNDr. Zuzana Černeková, PhD.  
**Katedra:** FMFI.KAI - Katedra aplikovanej informatiky  
**Vedúci katedry:** prof. Ing. Igor Farkaš, Dr.  
**Dátum zadania:** 13.10.2017

**Dátum schválenia:** 13.10.2017

prof. RNDr. Roman Ďurikovič, PhD.  
garant študijného programu

.....  
študent

.....  
vedúci práce

Čestne prehlasujem, že túto diplomovú prácu som  
vypracoval samostatne len s použitím uvedenej literatúry  
a za pomoci konzultácií u môjho školiteľa.

Bratislava, 2019

.....

Bc. Martin Sadloň

## ZDROJE

# Pod'akovanie

Ďakujem každému, kto sa svojou pomocou podieľal na vzniku tejto diplomovej práce. Predovšetkým chcem poďakovať RNDr. Zuzane Černekovej, PhD., za jej rady, ústretovosť, pripomienky a obetovaný čas na spoločných stretnutiach.

# Abstrakt

Martin Sadloň: Detekcia abnormálneho správania. (Diplomová práca) – Univerzita Komenského v Bratislave. Fakulta matematiky, fyziky a informatiky; Katedra aplikovanej informatiky. Školiteľ: RNDr. Zuzana Černeková, PhD.: FMFI UK, 2019, ?? strán.

Cieľom tejto diplomovej práce je analýza možných spôsobov detekcie, sledovania a klasifikácie správania osôb vo videu. Na základe vypracovanej analýzy je navrhnuté možné riešenie pre detekciu abnormálneho správania.

Kľúčové slová: abnormálne správanie, video, OpenCV

# Abstract

Martin Sadloň: Abnormal behavior detection. (Diploma Thesis) – Comenius University in Bratislava. Faculty of Mathematics, Physics and Informatics; Department of Applied Informatics. – Supervisor: RNDr. Zuzana Černeková, PhD: FMPH CU, 2019, ?? pages.

The aim of this diploma thesis is to analyze possible ways of detecting, tracking and lassifying humans behavior in video. On the basis of the analysis, a possible solution for detection of abnormal behavior is suggested.

Keywords: abnormal behavior, video, OpenCV



# Obsah

<b>1</b>	<b>Spracovanie obrazu</b>	<b>2</b>
1.1	Digitalizácia obrazu . . . . .	2
1.1.1	Vzorkovanie . . . . .	3
1.1.2	Kvantovanie . . . . .	4
1.2	Odstránenie šumu . . . . .	5
1.3	Segmentácia . . . . .	7
1.3.1	Prahovanie . . . . .	8
1.3.2	Segmentácia detekciou hrán . . . . .	9
1.4	Detekcia pohyblivých objektov . . . . .	10
1.4.1	Optical flow . . . . .	10
1.4.2	Analýza pohyblivých objektov na základe predchádzajúcich snímok . . . . .	11
1.4.3	Social force model . . . . .	12
<b>2</b>	<b>Analýza problému detekcie správania</b>	<b>13</b>
2.1	Detekcia správania použitím knižníc . . . . .	14
2.2	Klasifikovanie javov použitím učiacich sa algoritmov . . . . .	15
2.3	Popis trajektórie pohybu . . . . .	16
2.4	Definovanie neštandardného správania . . . . .	17

<i>OBSAH</i>	x
<b>3 Koncept aplikácie</b>	<b>18</b>
<b>4 Implementácia algoritmu detekcie správania</b>	<b>19</b>
<b>5 Analýza výsledkov</b>	<b>20</b>
<b>6 Diskusia</b>	<b>21</b>
<b>7 Záver</b>	<b>22</b>

# Úvod

Úvod práce, uvedenie do problematiky. Kapitola bude doplnená neskôr.

# Kapitola 1

## Spracovanie obrazu

Pre analýzu videa je dôležité aplikovať správne metódy spracovania obrazu. Video je potrebné rozdeliť na separátne snímky, z ktorých sa budú následne získavať dáta. Získavanie dát z obrazu je možné viacerými metódami. Cieľom tejto kapitoly je analyzovať tieto metódy a zamerať sa na existujúce riešenia problematiky spracovania obrazu, popísať ich princípy a vlastnosti. Spracovanie obrazu pozostáva z nasledujúcich krokov:

1. predspracovanie obrazu
2. segmentácia obrazu
3. analýza objektov a ich deskripcia

### 1.1 Digitalizácia obrazu

Snímače obrazu poskytujú na výstupe obrazovú funkciu v spojitom tvare. Spracovanie na počítači vyžaduje prevod do diskkrétnej podoby, čiže digitalizáciu. Tá je jedným z prvých krokov spracovania obrazu a pozostáva z dvoch častí:

1. vzorkovanie


2. kvantovanie

### 1.1.1 Vzorkovanie

Vzorkovaním rozumieme prevod spojitého obrazu do diskkrétnej formy. So zvyšujúcou sa hustotou vzorkovania narastá presnosť aproximácie spojitých funkcií na diskrétnu. Naopak, so znižujúcou vzorkovacou frekvenciou dochádza k postupnej strate informácie v obraze. Aby sme sa vyhli strate informácie a zároveň zachovali kvalitu obrazu, je potrebné správne určiť vzorkovaciu frekvenciu. *Shanonova veta o vzorkovaní* hovorí, že vzorkovacia frekvencia musí byť aspoň dvakrát väčšia ako maximálna frekvencia ktorú obsahuje vzorkovací signál.

$$f_{vzor} \geq 2f_{max}$$


Body dosiahnuté vzorkovaním voláme *pixely*. Tie možno usporiadať rôznym spôsobom do vzorkovacej mriežky (viď obr. 1.1). Najčastejšou reprezentáciou je *štvorcová mriežka*, ktorej body sú usporiadané horizontálne a vertikálne. Tento koncept využíva väčšina zobrazovacích zariadení. Výhodou *Hexagonálnej mriežky* je vlastnosť rovnakej vzdialenosti bodu od všetkých susedov daného bodu. Aj napriek tejto výhode sa nepresadila a dnes sa už používa iba sporadicky.



Obr. 1.1: Štvorcová a hexagonálna mriežka [Poc]

### 1.1.2 Kvantovanie

Kvantovanie je diskretizácia oboru hodnôt obrazovej funkcie. Obor hodnôt funkcie sa rozdelí na intervaly, ku ktorým je potom pridelená jedna reprezentatívna hodnota. Podľa spôsobu rozdelenia kvantovacej veličiny hovoríme o *uniformnom* a *neuniformnom kvantovaní*. Uniformné kvantovanie používa konštantnú dĺžku intervalu, kým neuniformné kvantovanie premenlivú dĺžku intervalu. Na výber reprezentatívnej hodnoty môžeme použiť rôzne techniky. Obvykle sa používa priemer hodnôt z celého intervalu, medián, priemer z hodnôt na okraji intervalu či váhovaný priemer. Počet kvantovacích úrovní musí byť dostatočne veľký, čo zamedzí vzniku falošných obrysov. To možno docieľiť práve vyššie spomenutým nelineárnym kvantovaním, kde sa zväčšuje rozsah tých intervalov jasů, ktoré sú v obraze málo zastúpené.



Obr. 1.2: Kvantovanie, zľava: 1 Bit, 2 Bity, 4 bity, 8 Bitov [Seg]

Kvantovať môžeme na rôzny počet úrovní (viď obr. 1.2). Pre účel neskoršieho spracovania a analýzy snímky videa je vhodné použiť kvantovanie napr. na 256 úrovní jasu, čo zodpovedá kódovaniu 8 bitmi. Týmto kvantovaním je možné docieľiť zníženie objemu dát a zároveň nestratiť obrazovú informáciu.

## 1.2 Odstránenie šumu

Táto kapitola opisuje najrozšírenejšie techniky odstraňovania nedostatkov v obraze spôsobených šumom. Odstránenie šumu je dôležitým procesom predspracovania obrazu. Šum môže sťažiť, v niektorých prípadoch až znemožniť spracovanie a analýzu obrazu za účelom detekcie správania. Existujú rôzne druhy šumu. Ako je uvedené v [Sum], podľa pravdepodobnostnej charakteristiky alebo podľa formy výstupu delíme šum na rôzne druhy, napr.:

1. *Gaussov šum* - zasahuje všetky pixely v obraze, no hodnoty pixelov zväčša ostávajú zachované; hodnoty amplitúd šumu bývajú výrazne nižšie ako hodnoty pixelov
2. *Impulzný šum* - prejavuje sa výrazne odlišnou hodnotou oproti hodnote signálu, resp. náhodným výskytom bielych pixelov; špeciálnym prípadom je *salt and pepper* (náhodný výskyt bielych a čiernych pixelov)
3. *Kvantizačný šum* - vzniká pri digitalizácii obrazu
4. *Aditívny šum* - vzniká pričítaním k pôvodným hodnotám pixelov, jeho spracovanie je najjednoduchšie
5. *Multiplikatívny šum* - vzniká vynásobením každej hodnoty pixelu amplitúdou šumu tohto pixelu



Obr. 1.3: Ukážka šumu, zľava: originálny obraz, Gaussov šum, salt and pepper [Sum]


Pre dosiahnutie lepšej kvality získavania dát z obrazu je odstránenie šumu nevyhnutnou súčasťou. Existuje viacero metód používaných pri odstraňovaní tejto anomálie. Správnou metódou možno výrazne zvýšiť kvalitu obrazu. Medzi najčastejšie používané filtre [Poc] na odstránenie šumu vo videu môžeme zaradiť tieto:

1. *Gaussov filter* - patrí medzi lineárne vyhladzovacie filtre, je reprezentovaný charakteristickou Gaussovou krivkou, výsledkom je vážený priemer okolia každého pixelu, pričom váhy sú vyššie smerom k stredovým pixelom jadra (metóda vhodná na potlačenie Gaussovho šumu)
2. *Priemerovací filter* - členy filtračného jadra sú definované tak, aby výsledkom konvolúcie bol aritmetický priemer okolia bodu daného veľkosťou použitého filtra
3. *Mediánový filter* - patrí medzi nelineárne vyhladzovacie filtre, jasové hodnoty vpadajúce do filtračnej masky sú usporiadané podľa veľkosti, pričom nová jasová hodnota je vypočítaná ako medián tejto postupnosti (metóda vhodná na potlačenie impulzného šumu)



## 1.3 Segmentácia

Pri procese detekcie osôb na videu a analýze správania je potrebné tieto osoby správne segmentovať. Pod pojmom segmentácia rozumieme rozdelenie obrazu na oblasti s určitými vlastnosťami. V ideálnom prípade tieto oblasti reprezentujú objekty reálneho sveta (v našom prípade osoby). Podľa úrovne rozdeľujeme segmentáciu na *úplnú* (segmentované objekty priamo zodpovedajú hľadaným objektom reálneho sveta) a *čiasťočnú* (získané časti obrazu sú homogénne na základe nejakej vlastnosti, ako napr. farba, jas, textúra a pod.). Pre ilustráciu viď. obrázok 1.4.



Obr. 1.4: Segmentácia; zľava: originálny obraz, čiastočná segmentácia, úplná segmentácia

Pri segmentácii obrazu sa kladie dôraz na nasledujúce požiadavky:

1. *úplnosť* - segmentácia relevantných objektov
2. *efektívnosť* - čo najlepšie výsledky v čo najkratšom čase
3. *nezávislosť* - používateľ vstupuje do procesu segmentácie v čo najmenej možnej miere

Najjednoduchší a častokrát používaný prístup detekcie objektov je založený na princípe, kde používateľ manuálne v obraze vyznačí oblasť, v ktorej sa objekt (v našom prípade osoba) nachádza. Tento prístup je efektívny a

menej náročný na výkon systému, avšak porušuje tretiu vyššie uvedenú požiadavku - nezávislosť vstupu používateľa. Preto je tento prístup používaný iba pre prípady, kedy sa požaduje nízka náročnosť na výkon a nie je potrebná úplná automatizácia.

V nasledujúcich podkapitolách spomenieme niektoré z najpoužívanějších metód segmentácie objektov v obraze.

### 1.3.1 Prahovanie

Ako je uvedené v [Seg], prahovanie je najjednoduchšia segmentačná technika, ktorá je rýchla, výpočtovo nenáročná a nepotrebuje vstup používateľa. Na segmentovanie objektov od pozadia sa používa jasová konštanta, ktorá sa nazýva *prah*. Pri prahovaní s jedným globálnym prahom hovoríme o *globálnom prahovaní*. Hodnota prahu sa vopred vypočíta a aplikuje na celý obraz. Takáto metóda je úspešná iba pri veľmi špecifických prípadoch, kedy má pozadie výrazne odlišnú jasovú zložku od popredia.

Pre lepšie výsledky možno prah meniť adaptívne v závislosti od jednotlivých častí obrazu. Vtedy hovoríme o *adaptívnom prahovaní*. Prahová hodnota sa vypočítava separátne pre každý bod obrazu. Existujú dve základné metódy výpočtu adaptívnej prahovej hodnoty:

1. *Chow a Kanenho metóda[Seg]* - Obraz rozdelíme na množinu menších častí, následne skúmaním histogramu pre každú obrazovú časť zistíme príslušný optimálny prah. Prahovú hodnotu pre konkrétny bod vypočítame interpoláciou prahových hodnôt podobrazov. Nevýhodou tejto metódy je výpočtová náročnosť, metóda preto nie je vhodná pre aplikácie bežiacie v reálnom čase.
2. *Lokálne prahovanie* - Pre každý bod si zvolíme malé okolie, pomocou

ktorého vypočítame prahovú hodnotu. Na výpočet prahovej hodnoty môžeme použiť priemer, medián alebo strednú hodnotu minimálnej a maximálnej jasovej hodnoty v okolí.

### 1.3.2 Segmentácia detekciou hrán

Jedným z prístupov ako automaticky rozoznať objekty je hranová segmentácia. Táto metóda je založená na získavaní údajov z hrán v obraze. Hranu môžeme popísať ako miesto, kde sa prudko mení jas obrazu. Pri segmentácii sa sústredíme hlavne na miesta, kde sa vyskytuje takzvaná hranica objektu. Hranicou objektu definujeme skupinu bodov, v ktorej sa nachádza aspoň jeden pixel, ktorý nie je jeho súčasťou. Dôležitou časťou je, aby získané hrany boli zreťazené a tak vytvárali určitú oblasť, v ktorej sa objekt nachádza. Takýto postup je možný, iba ak poznáme vlastnosť hľadaného objektu. Použitím vlastnosti vieme určiť, či daná oblasť zodpovedá pozorovanému objektu. Medzi tieto vlastnosti patrí napríklad farba alebo textúra. Následne sa sústreďujeme už len na pohyblivé hranice. Na základe zmeny týchto častí získaných zo segmentácií dokážeme určiť správanie sa daného objektu. Changick Kim a Jenq-Neng Hwang v práci [KH02] navrhli práve tento postup, kde rozpoznaním hrán odlíšime objekt od jeho pozadia a tak získame obraz obsahujúci len potrebný objekt. Na obrázku 1.5 môžeme vidieť aplikáciu popísaného algoritmu.



Obr. 1.5: Hranová detekcia [KH02]


## 1.4 Detekcia pohyblivých objektov

Pohyb v obraze môžeme definovať ako zmenu porovnávanej snímky oproti predchádzajúcej snímke. Pri detekcii správania je dôležité odlíšiť sledované objekty od statických. Ďalej je dôležité rozlíšiť či zmena, ktorá bola zistená bola výrazná, a teda nedošlo len k zmene podmienok snímania, čo mohol spôsobiť jeden z nasledujúcich faktorov:

1. znížený jas
2. pohyb kamery
3. šum

### 1.4.1 Optical flow

Metóda Optical Flow je jednou z najpoužívanějších techník na detekciu pohybu v obraze. Pre výpočet optického toku existujú rôzne implementácie [BFB94], ktoré sa snažia optimalizovať postup jeho výpočtu. Výsledkom je získavanie smeru a rýchlosti pohybu pre každý pixel. Keďže výpočet je realizovaný pre všetky pixely, to má za následok, že použitie tejto metódy v aplikáciach bežiacich v reálnom čase môže byť náročné, alebo nepresné. Aby sa zredukoval počet iterácií, v ktorých sa vykonáva výpočet optického toku je potrebné aby sa určilo, pre ktoré pixely je potrebný tento výpočet. Taktiež je možné, ak to typ videozáznamu umožňuje, niektoré snímky videa vynechať pre urýchlenie procesu a vyberať napr. každú druhú snímku (počet vybraných snímok závisí od snímkovacej frekvencie videozáznamu). K určeniu takzvaných záujmových oblastí je vhodné použiť niektorú z metód segmentácie objektov a tak získať len tie pixely, ktoré tvoria hranicu objektu a následne realizovať výpočet len pre tieto oblasti.



Obr. 1.6: Detekcia pohybu algoritmom Optical Flow; vľavo: snímka videa, vpravo: na snímku je aplikovaný Optical Flow zvýrazňujúci červené vektory pohybu

### 1.4.2 Analýza pohyblivých objektov na základe predchádzajúcich snímok

Metóda bola prvýkrát predstavená Bobickom a Davisom vo svojej práci [DB97]. Tiež známa ako MHI. Cieľom je extrahovanie pohybu z predošlého záznamu. MHI spracováva obraz tak, že intenzita pixelu predstavuje aktuálnosť pohybu v sekvencií snímok.

Na definovanie tejto metódy najprv extrahujeme len pohyblivé časti obrazu  $D(x, y, t)$  z pôvodnej snímky  $I(x, y, t)$ . To sa vykoná porovnaním oboch snímok. Následne každý pixel nachádzajúci sa na predošlej snímke  $H_i$  vyjadruje funkciu pohybu daného bodu, ktorá nastala počas dĺžky  $t$ . Táto funkcia popísaná v [RMSAR07] vyjadruje obdobie minulosti pre daný bod.

$$H_i(x, y, t) = \begin{cases} \tau & \text{ak } D(x, y, t) = 1 \\ \max(0, H_i(x, y, t-1)) & \text{inak} \end{cases}$$

Výsledkom je obraz, v ktorom sú pohyblivé pixely svetlejšie oproti ostat-

ným. Využitie tejto metódy nachádzame hlavne v oblastiach, kde sledujeme pohybovú aktivitu ako je napríklad:

- *chôdza človeka*
- *náhla zmena v pohybe*
- *sledovanie netypických činností*
- *neaktívnosť objektu*
- *sledovanie správania*

### 1.4.3 Social force model

Podľa [MOS09] je Social Force Model metóda na detekciu a lokalizáciu abnormálneho správania v početnejších davoch ľudí. Pre tento účel je na obraz umiestnená mriežka častíc, podobne ako pri metóde Optical Flow. Interakčné sily medzi jednotlivými časticami sú odhadované pomocou Social Force Model-u a tieto sily sú následne mapované do obrazu pre získanie Force Flow pre každý pixel v každej snímke videa. Náhodne vybraný objem Force Flow je následne použitý na modelovanie detekcie správania. Miesta v obraze vyhodnotené ako abnormálne sú lokalizované pomocou interakčných síl.

## Kapitola 2

# Analýza problému detekcie správania

Na základe predošlého spracovania dokážeme získať obraz, ktorý vieme ďalej pozorovať. Klasifikácia stavov jednotlivých objektov závisí od pozorovania ich vlastností. Pozorovaním týchto vlastností dokážeme klasifikovať správanie a určiť jeho typ. Pre rozlíšenie správania existujú viaceré postupy.

Abnormálne správanie popisujeme ako anomálie, ktoré sa nezhodujú s vopred definovaným správaním alebo správanie sa vychýľuje doposiaľ známemu správaniu. Aby sme mohli detegovať dané správanie ako abnormálne je potrebné, aby sa vopred vytvorila sada štandardných správání. Porovnaním jednotlivých objektov vyhodnotíme typ správania. Vytvorenie jednotlivých sád môžeme dosiahnuť či už presným definovaním, alebo vytvorením určitých požiadaviek, ktoré musí dané správanie spĺňať. Tento predpoklad môžeme dosiahnuť staticky alebo dynamicky. Pod statickou sadou rozumieme presne vopred určené druhy správania, ktoré sú považované za štandardné. Naopak dynamická sada správania je vytváraná počas doby detekcie pohybov. Jednotlivé pohyby sú ukladané a na základe testovaní sú ďalej rozlišované a

kategorizované.

## 2.1 Detekcia správania použitím knižníc

Ako pomoc pre ľahšie určenie typu správania boli vytvorené viaceré knižnice, v ktorých sa nachádzajú už vopred preddefinované vzory pohybov. Porovnaním získaných dát s týmito vzormi môžeme jednoducho klasifikovať daný pohyb. Pre optimalizáciu výkonu je potrebné vopred zvoliť, s ktorými knižnicami sa bude scéna porovnávať, pretože niektoré knižnice obsahujú množstvo preddefinovaných prípadov. Mezi tieto knižnice patria:

- **KTH knižnica** [SLC04] obsahuje aktivity ako box, chôdza, beh, mávanie alebo tleskanie, všetky tieto aktivity sú situované do rôznych prostredí
- **Hollywood knižnica** [LMSR08] v tejto knižnici sa nachádzajú aktivity ako sadanie si, podávanie si rúk alebo vstávanie
- **LIRIS knižnica** [WML<sup>+</sup>12] táto knižnica obsahuje aktivity ako otváranie a zatváranie dverí, vchádzanie a vychádzanie z dverí a písanie na počítači
- **HMDB knižnica** [KJG<sup>+</sup>11] rozsiahla knižnica obsahujúca viac ako 50 rôznych aktivít

Všetky tieto aktivity sú vytvorené viacerými ľuďmi a sú snímané z rôznych scén. Porovnaním záznamu získaného z kamery a scénami z knižníc, sme nielen schopní určiť daný pohyb, ale tiež vyhodnotiť jeho stav.



## 2.2 Klasifikovanie javov použitím učiacich sa algoritmov

Učiace sa algoritmy dokážu na základe získaných dát zlepšiť svoju činnosť rozhodovania a tak zefektívniť konečný výpočet. Aby sme dokázali rozlíšiť dané javy, môžeme použiť niekoľko samoučiacich algoritmov. Tieto algoritmy môžeme rozdeliť na:

1. s použitím učiteľa, ak poznáme očakávaný vstup
2. bez použitia učiteľa, ak nepoznáme očakávaný vstup
3. učenie sa zo získanej spätnej väzby

Zo získaných dát je vytvorený model založený na vopred daných inštrukciách rozdeľovania a rozhodovania. Pri tomto algoritme predpokladáme, že vstupné dáta obsahujú aj nerozpoznané aj rozpoznané javy. Medzi rozpoznané javy zaraďujeme tie, ktoré sme zlúčili na základe podobnosti a označili ako štandardné. Ako neštandardné môžeme označiť tie, ktoré sa vyskytujú na neočakávaných miestach, alebo ich pravdepodobnosť výskytu je nízka. Pre vytvorenie modelu obsahujúci všetky javy môžeme použiť Gaussov zložený model. Tento model sa používa na odhad hustoty funkcie nameraných hodnôt. Oblasť s nízkou hustotou môžeme klasifikovať ako oblasť možných abnormálnych javov. Použitím metódy pre odhad hustoty jadier dokážeme rozdeliť nezaradené dáta vyskytujúce sa v modeli. Detekcia anomálií použitím Gumbeloveho rozdelenia bola použitá v práci [Rob99], kde hľadaním maximálnych a minimálnych hodnôt v modeli získavame oblasti možných abnormálnych výskytov. Zväčšovaním modelu narastá cena výpočtu. Aby sme znížili množstvo dát, pre ktoré je potrebné realizovať výpočet, je potrebné

zlučovať jednotlivé trajektórie. Pri tomto kroku môžeme brať do úvahy parametre ako váha, medián a kovariancia trajektórií na základe porovnania týchto parametrov môžeme jednotlivé trajektórie zlúčiť.

## 2.3 Popis trajektórie pohybu

Nato aby sme mohli daný pohyb podrobne analyzovať potrebujeme popísať jeho trajektóriu. Trajektória pohybu je definovaná pomocou polohového vektora  $r$ , vyjadrená ako funkcia času  $t$ :

$$r = r(t)$$

Dĺžku danej trajektórie definujeme ako vzdialenosť, ktorú prejde daný bod za určitý čas  $t$ :

$$s = s(t)$$

Každá trajektória, ktorú chceme popísať by mala zahŕňať tieto vlastnosti:

- rozširiteľnosť, popis trajektórie nezáleží od daného prostredia
- schopnosť opísať akýkoľvek pohyb
- premenlivosť, dĺžka trajektórie nijako neovplyvní jej popísanie

## 2.4 Definovanie neštandardného správania

Klasifikovať správanie ako neštandardné môžeme na základe nasledujúcich predpokladov:

- trajektória, ktorá popisuje pohyb je odlišná od preddefinovaných trajektórií
- pohyb sa objavil na mieste, kde sa doposiaľ nevyskytoval
- pohyb daného objektu je nerovnomerný
- pohyb je výrazne iný ako vopred preddefinovaný

Ak pohyb objektov, ktorý sme získali spĺňa aspoň jeden z týchto predpokladov, môžeme ho klasifikovať ako neštandardný, resp. abnormálny.

## Kapitola 3

### Koncept aplikácie

## Kapitola 4

# Implementácia algoritmu detekcie správania

## Kapitola 5

### Analýza výsledkov

## Kapitola 6

## Diskusia

Kapitola 7

Záver



## Zdroje

## Prílohy

# Literatúra

- [BFB94] John L Barron, David J Fleet, and Steven S Beauchemin. Performance of optical flow techniques. *International journal of computer vision*, 12(1):43–77, 1994.
- [DB97] James W Davis and Aaron F Bobick. The representation and recognition of human movement using temporal templates. In *Computer Vision and Pattern Recognition, 1997. Proceedings., 1997 IEEE Computer Society Conference on*, pages 928–934. IEEE, 1997.
- [KH02] Changick Kim and Jenq-Neng Hwang. Fast and automatic video object segmentation and tracking for content-based applications. *IEEE transactions on circuits and systems for video technology*, 12(2):122–129, 2002.
- [KJG<sup>+</sup>11] Hildegard Kuehne, Hueihan Jhuang, Estíbaliz Garrote, Tomaso Poggio, and Thomas Serre. Hmdb: a large video database for human motion recognition. In *Computer Vision (ICCV), 2011 IEEE International Conference on*, pages 2556–2563. IEEE, 2011.
- [LMSR08] Ivan Laptev, Marcin Marszalek, Cordelia Schmid, and Benjamin

- Rozenfeld. Learning realistic human actions from movies. In *Computer Vision and Pattern Recognition, 2008. CVPR 2008. IEEE Conference on*, pages 1–8. IEEE, 2008.
- [MOS09] Ramin Mehran, Alexis Oyama, and Mubarak Shah. Abnormal crowd behavior detection using social force model. In *Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE Conference on*, pages 935–942. IEEE, 2009.
- [Poc] Počítačové videnie v praxi. [http://home.saske.sk/~tomori/Downloads/Poc\\_videnie/PV\\_2016.pdf](http://home.saske.sk/~tomori/Downloads/Poc_videnie/PV_2016.pdf). Navštívené: 9. január 2019.
- [RMSAR07] Caroline Rougier, Jean Meunier, Alain St-Arnaud, and Jacqueline Rousseau. Fall detection from human shape and motion history using video surveillance. In *Advanced Information Networking and Applications Workshops, 2007, AINAW'07. 21st International Conference on*, volume 2, pages 875–880. IEEE, 2007.
- [Rob99] Stephen J Roberts. Novelty detection using extreme value statistics. *IEE Proceedings-Vision, Image and Signal Processing*, 146(3):124–129, 1999.
- [Seg] Počítačové videnie v praxi. <http://sccg.sk/~ftacnik/IP-5.pdf>. Navštívené: 9. január 2019.
- [SLC04] Christian Schuldt, Ivan Laptev, and Barbara Caputo. Recognizing human actions: a local svm approach. In *Pattern Recognition, 2004. ICPR 2004. Proceedings of the 17th International Conference on*, volume 3, pages 32–36. IEEE, 2004.

- [Sum] Metody pro odstránění šumu z digitálních obrazů.  
[https://www.vutbr.cz/www\\_base/zav\\_prace\\_soubor\\_verejne.php?file\\_id=52363](https://www.vutbr.cz/www_base/zav_prace_soubor_verejne.php?file_id=52363). Navštívené: 8. január 2019.
- [WML<sup>+</sup>12] Christian Wolf, Julien Mille, Eric Lombardi, Oya Celiktutan, Mingyuan Jiu, Moez Baccouche, Emmanuel Dellandréa, Charles-Edmond Bichot, Christophe Garcia, and Bülent Sankur. The liris human activities dataset and the icpr 2012 human activities recognition and localization competition. *LIRIS Umr 5205 CNRS/INSA Lyon/Universite'Claude Bernard Lyon 1/Universite'Lumie 're Lyon 2/E'cole Cent*, 2012.

# Zoznam obrázkov

1.1	Štvorcová a hexagonálna mriežka [Poc] . . . . .	4
1.2	Kvantovanie, zľava: 1 Bit, 2 Bity, 4 bity, 8 Bitov [Seg] . . . . .	4
1.3	Ukážka šumu, zľava: originálny obraz, Gaussov šum, salt and pepper [Sum] . . . . .	6
1.4	Segmentácia; zľava: originálny obraz, čiastočná segmentácia, úplná segmentácia . . . . .	7
1.5	Hranová detekcia [KH02] . . . . .	9
1.6	Detekcia pohybu algoritmom Optical Flow; vľavo: snímka videa, vpravo: na snímku je aplikovaný Optical Flow zvýrazňujúci červené vektory pohybu . . . . .	11